

1.问题和语料

本报告集中研究Woloch所提出的人物空间是否能用统计方法操作化，人物空间是角色在叙事中占据具体且有限的位置，以老舍《骆驼祥子》为语料并通过搭配词分析该语料。本次分析所使用的语料来源为GitHub仓库：mcjkurz/qhchina-data的中文小说100强目录，经过清理和转简体处理过的文本约为13.4万个字符，分句、分词并过滤短句后的文本规模为4427句和72970词。研究选择了主人公祥子作为分析对象，选择祥子的核心原因在于他的主人公身份及较多的姓名语境，而“祥子”在保留句中出现了736次，约为虎妞的4倍，因此叙事高度围绕着祥子。除此之外，祥子尽管作为小说的核心人物，自己说的话却很少，这正能让我们追问：除了对话以外，他的空间由什么填满？据此，本报告主要回答两个问题：在文本中哪类词填满了祥子的人物空间，以及搭配词能在多大程度上代表人物空间。本报告认为，透过搭配词分析语料可以检索哪类词与“祥子”共现的频率高于随机预期，但共现无法直接确定搭配词的描写对象，即使搭配词在描写祥子也无法直接确定在服务祥子。因此，人物空间只能通过搭配词部分操作化。

2.文本预处理

文本预处理由 segment.py 完成，首先对文本进行清理，清除目录、版次、书名、每一章的章节编号和末尾的“（全书完）”。语料的原文基本为简体，仍然按照作业要求使用了OpenCC的t2s统一转为简体中文，之后按标点符号“。？！”切分句子。下一步是使用jieba分词，在这一步中需要先给“祥子”设置高权重，否则“祥子”和旁边的字可能会连在一起成为一个词，导致部分“祥子”无法被识别。最后对处理完成后的句子进行过滤，只保留有至少5个词的句子，这导致了639句短句被过滤，其中祥子从801次减少到736次，部分共现因此会无法被统计，被过滤的句子中，有不少是描写祥子的沉默的句子，这使部分沉默表达未能进入分析。

3.方法与统计

搭配词分析使用了qhchina 0.2.7的find_collocates，目标词为“祥子”，三次运行使用了窗口模式（horizon=5、horizon=10）和句子模式，以比较不同设置下的结果。过滤设置使用了min_word_length=2和max_p=0.05，以确保能聚焦于至少有两个字的词和只保留统计上显著的搭配词。另外，使用load_stopwords载入了806个停用词，并只从结果中排除这些停用词，确保词距不会被压缩。以句子模式为例，列联表是把文本中所有句子，按照有没有“祥子”和有没有“心中”分成4类来数，如此便可以找到同时有“祥子”和“心中”的句子有40句。假设“祥子”和“心中”毫无关系，预期次数是 $149 \times 693 / 4,427 \approx 23.3$ 句，实际为40句，比值约为 $40 / 23.3 \approx 1.71$ 。另外，窗口模式的逻辑相同，但单位是词的位置，所以两种模式的次数不能直接比较。假设两词毫无关系，统计到的p值就是仍然看到这么多或更多共现的概率，并且只有p值小于0.05，就可以认为“不太可能是偶然”，以“祥子”和“心中”为例，“心中”的p值为0.00026，对比“小福子”的0.28，高于0.05，因此不显著。在Fisher检验的部分，选择的参数是greater，这能得知共现次数是否比预期次数异常地多以及祥子的

空间被什么词围绕着，但使用该方法的代价是无法检索共现次数是否比预期次数异常地少，无法得知祥子的空间没被什么词围绕着。

4.结果与比较

三次运行分别得到94、110和114个显著搭配词，其中42个显著搭配词是三次运行共有的。

关键词	窗口5	窗口10	句子模式
心中	21 ✓	31 ✓	40 ✓
先生	21 ✓	40 ✓	41 ✓
言语	5 ✓	5 ✓	5 ✓
小福子	13 ✓	15 ✓	15 ✕
虎妞	16 ✕	32 ✓	40 ✓
刘四爷（四爷）	7 ✕	13 ✕	15 ✕

数字代表共现次数，✓代表p值小于0.05，✕代表不显著。

在三次运行共有的42个显著搭配词中，大致可分为内心（心中）、知觉（看见）、动作（低著头）、表情（脸红）和人物（先生），其中与言语相关的词“言语”、“没说”也在42个共有的显著搭配词中。另外，在三次运行的结果中，有些词只在近距离才显著，有些词只在远距离显著，例如虎妞在窗口5的p值为0.136，到窗口10却排第2名，相反，小福子只有在近距离（窗口模式）显著，到了远距离（句子模式）却不显著，p值为0.279。除此之外，还发现了统计上不显著，但对故事情节重要的“刘四爷”在使用jieba分词时被切割为“刘”和“四爷”，三次运行中“四爷”都不显著，但别称“老头子”在窗口模式中显著。这些规律对祥子的人物空间意味着什么？

5.解释

搭配词的价值在于有比较基准，能把叙事资源的分配变成可以观察的分布。如果人物空间是叙事资源的分配，那么就可以视为内心描写也是其中一种叙事资源。祥子身边围绕着“心中”和“低著头”这些内心类和身体类的词，可能的原因在于小说的叙事一直围绕着祥子，且祥子在故事中表现得不善言辞，身体代替语言作出反应。取消过滤停用词“说”之后，发现祥子和“说”显著共现（76句，预期约47.9句），其中约四分之一写他说不出或说得吃力。这说明了叙事分配给祥子的关注，主要是内心和身体，而不是祥子的语言，因此人物的空间是有着构成之分的。

然而，共现并不必然代表搭配词是在描写目标词，以“言语”为例，这个词与祥子共现5次，其中3次确实是祥子“没言语”，但有1次是描写太太的不言语，有1次是虎妞心想跟著祥子的快活，又不是言语所能形容的。Woloch真正关心的，是叙事资源到底分配给了谁，只从描写的角度来说，使用搭配词方法并不能直接分辨搭配词是属于哪个角色的，即使是最稳定的“心中”，40句中也有4句属于虎妞、刘四爷等人，还有1句是分词误差，因此统计虽大致可信，但是仍会高估祥子的内心空间。

更进一步，即使该方法能分辨搭配词描写的是谁，也不能必然地正确分辨搭配词为谁的故事服务。在前文虎妞的例子中，描写的角色确实是虎妞，但这一段描写却是围绕着祥子的。即使描写的对象并非目标词“祥子”，却恰好因为该句虎妞的描写服务于祥子而符合Woloch所说的次要人物被功能化。

6. 方法反思与结论

窗口大小改变了靠近的定义，虎妞在窗口5不显著，在窗口10却排第2，小福子正好相反，到句子模式就不显著了。可见搭配词的结果在一定程度上取决于设定的参数。如果分析语料换成其他老舍的作品，便可以比较不同主人公的搭配词，从而检验某些搭配词是祥子特有的。分析以“祥子”作为目标词，但文中多以代词“他”来指代祥子，因此，某些本应存在于祥子人物空间的词会因此变得不显著，但如果以“他”作为目标词，就能覆盖更多写祥子的句子，但“他”却会把其他男性人物算进来。可见目标词的选择决定了统计能看到的人物空间的范围。

回到开头的问题，搭配词能显示哪类词与“祥子”共现的频率高于随机预期，例如内心、知觉、身体，而言语类多为否定。但共现无法直接确定搭配词的描写对象，即使搭配词在描写祥子也无法直接确定在服务祥子，同时也只能检索名字附近的词，并不能直接表明人物的篇幅、视角和关注度。因此，人物空间只能被部分地操作化，统计结果必须与实际细读结合。