

1.问题和语料

本报告集中研究 Woloch 所提出的人物空间是否能用统计方法操作化，人物空间是角色在叙事中占据具体且有限的位置，以老舍《骆驼祥子》为语料并通过搭配词分析该语料。本次分析所使用的语料来源为 GitHub 仓库：mcjkurz/qhchina-data 的中文小说 100 强目录，经过清理和转简体处理过的文本约为 13.4 万个字符，分句、分词并过滤短句后的文本规模为 4427 句和 72970 词。研究选择了主人公祥子作为分析对象，选择祥子的核心原因在于他的主人公身份及较多的姓名语境，而“祥子”在保留句中出现了 736 次，约为虎妞的 4 倍，因此叙事高度围绕着祥子。除此之外，祥子尽管作为小说的核心人物，自己说的话却很少，这正能让我们追问：除了对话以外，他的空间由什么填满？据此，本报告主要回答两个问题：在文本中哪类词填满了祥子的人物空间，以及搭配词能在多大程度上代表人物空间。本报告认为，透过搭配词分析语料可以检索哪类词与“祥子”共现的频率高于随机预期，但共现无法直接确定搭配词的描写对象，即使搭配词在描写祥子也无法直接确定在服务祥子。因此，人物空间只能通过搭配词部分操作化。

2.文本预处理

文本预处理由 `segment.py` 完成，首先对文本进行清理，清除目录、版次、书名、每一章的章节编号和末尾的“（全书完）”。语料的原文基本为简体，仍然按照作业要求使用了 OpenCC 的 `t2s` 统一转为简体中文，之后按标点符号“。？！”切分句子。下一步是使用 `jieba` 分词，在这一步中需要先给“祥子”设置高权重，否则“祥子”和旁边的字可能会连在一起成为一个词，导致部分“祥子”无法被识别。最后对处理完成后的句子进行过滤，只保留有至少 5 个词的句子，这导致了 639 句短句被过滤，其中祥子从 801 次减少到 736 次，部分共现因此会无法被统计，被过滤的句子中，有不少是描写祥子的沉默的句子，这使部分沉默表达未能进入分析。

3.方法与统计

搭配词分析使用了 `qhchina 0.2.7` 的 `find_collocates`，目标词为“祥子”，三次运行使用了窗口模式（`horizon=5`、`horizon=10`）和句子模式，以比较不同设置下的结果。过滤设置使用了 `min_word_length=2` 和 `max_p=0.05`，以确保能聚焦于至少有两个字的词和只保留统计上显著的搭配词。另外，使用 `load_stopwords` 载入了 806 个停用词，并只从结果中排除这些停用词，确保词距不会被压缩。以句子模式为例，列联表是把文本中所有句子，按照有没有“祥子”和有没有“心中”分成 4 类来数，如此便可以找到同时有“祥子”和“心中”的句子有 40 句。假设“祥子”和“心中”毫无关系，预期次数是

149×693/4,427≈23.3 句，实际为 40 句，比值约为 40/23.3≈1.71。另外，窗口模式的逻辑相同，但单位是词的位置，所以两种模式的次数不能直接比较。假设两词毫无关系，统计到的 p 值就是仍然看到这么多或更多共现的概率，并且只有 p 值小于 0.05，就可以认为“不太可能是偶然”，以“祥子”和“心中”为例，“心中”的 p 值为 0.00026，对比“小福子”的 0.28，高于 0.05，因此不显著。在 Fisher 检验的部分，选择的参数是 greater，这能得知共现次数是否比预期次数异常地多以及祥子的空间被什么词围绕着，但使用该方法的代价是无法检索共现次数是否比预期次数异常地少，无法得知祥子的空间没被什么词围绕着。

4.结果与比较

三次运行分别得到 94、110 和 114 个显著搭配词，其中 42 个显著搭配词是三次运行共有的。

关键词	窗口 5	窗口 10	句子模式
心中	21 ✓	31 ✓	40 ✓
先生	21 ✓	40 ✓	41 ✓
言语	5 ✓	5 ✓	5 ✓
小福子	13 ✓	15 ✓	15 X
虎妞	16 X	32 ✓	40 ✓
刘四爷（四爷）	7 X	13 X	15 X

数字代表共现次数，✓代表 p 值小于 0.05，X 代表不显著。

在三次运行共有的 42 个显著搭配词中，大致可分为内心（心中）、知觉（看见）、动作（低著头）、表情（脸红）和人物（先生），其中与言语相关的词“言语”、“没说”也在 42 个共有的显著搭配词中。另外，在三次运行的结果中，有些词只在近距离才显著，有些词只在远距离显著，例如虎妞在窗口 5 的 p 值为 0.136，到窗口 10 却排第 2 名，相反，小福子只有在近距离（窗口模式）显著，到了远距离（句子模式）却不显著，p 值为 0.279。除此之外，还发现了统计上不显著，但对故事情节重要的“刘四爷”在使用 jieba 分词时被切割为“刘”和“四爷”，三次运行中“四爷”都不显著，但别称“老头子”在窗口模式中显著。这些规律对祥子的人物空间意味着什么？

5.解释

搭配词的价值在于有比较基准，能把叙事资源的分配变成可以观察的分布。如果人物空间是叙事资源的分配，那么就可以视为内心描写也是其中一种叙事资源。祥子身边围绕着“心中”和“低著头”这些内心类和身体类的词，可能的原因在于小说的叙事

一直围绕着祥子，且祥子在故事中表现得不善言辞，身体代替语言作出反应。取消过滤停用词“说”之后，发现祥子和“说”显著共现（76句，预期约47.9句），其中约四分之一写他说不出或说得吃力。这说明了叙事分配给祥子的关注，相当一部分是内心和身体，而不是祥子的语言，因此人物的空间是有所构成的。

然而，共现并不必然代表搭配词是在描写目标词，以“言语”为例，这个词与祥子共现5次，其中3次确实是祥子“没言语”，但有1次是描写太太的不言语，有1次是虎妞心想跟着祥子的快活，又不是言语所能形容的。Woloch真正关心的，是叙事资源到底分配给了谁，只从描写的角度来说，使用搭配词方法并不能直接分辨搭配词是属于哪个角色的，即使是最稳定的“心中”，40句中也有4句属于虎妞、刘四爷等人，还有1句是分词误差，因此统计虽大致可信，但是仍会高估祥子的内心空间。

更进一步，即使该方法能分辨搭配词描写的是谁，也不能必然地正确分辨搭配词为谁的故事服务。在前文虎妞的例子中，描写的角色确实是虎妞，但这一段描写却是围绕着祥子的。即使描写的对象并非目标词“祥子”，却恰好因为该句虎妞的描写服务于祥子而符合Woloch所说的次要人物被功能化。

6.方法反思与结论

窗口大小改变了靠近的定义，虎妞在窗口5不显著，在窗口10却排第2，小福子正好相反，到句子模式就不显著了。可见搭配词的结果在一定程度上取决于设定的参数。如果分析语料换成其他老舍的作品，便可以比较不同主人公的搭配词，从而检验某些搭配词是祥子特有的。分析以“祥子”作为目标词，但文中多以代词“他”来指代祥子，因此，某些本应存在于祥子人物空间的词会因此变得不显著，但如果以“他”作为目标词，就能覆盖更多写祥子的句子，但“他”却会把其他男性人物算进来。可见目标词的选择决定了统计所能看到的人物空间的范围。

回到开头的问题，搭配词能显示哪类词与“祥子”共现的频率高于随机预期，例如内心、知觉、身体，而言语类多为否定。但共现无法直接确定搭配词的描写对象，即使搭配词在描写祥子也无法直接确定在服务祥子，同时也只能检索名字附近的词，并不能直接表明人物的篇幅、视角和关注度。因此，人物空间只能被部分地操作化，统计结果必须与实际细读结合。